


# GPU 显存占用分解 (8K 上下文)



红色虚线 = 常见 GPU 显存上限，柱体超过虚线则需降级精度或换卡