

Phase 1: PoC 验证

硬件
1×RTX 4090 24GB
64GB RAM, 2TB NVMe
Ubuntu 24.04 LTS

推理框架
vLLM + Ollama

模型
Qwen2.5-Coder-32B-Q4

RAG
Chroma + BGE-M3

能力
代码补全 · 文档问答
脚本生成

团队
3-8 人 PoC

RTX 4090 PoC 上线

RAG 全文档接入

↑ 积累数据

Phase 2: 团队部署

硬件
2×RTX 4090 / RTX 5090
128GB RAM, 4TB NVMe
Ubuntu 24.04 LTS

推理框架
vLLM + SGLang

模型
Qwen2.5-72B-Q4 主力
DeepSeek-Coder-V2

RAG
Qdrant + 全公司文档

能力
完整 RAG · LoRA 微调
Agent 原型

团队
10-30 人正式使用

Agent 非关键路径

↑ 扩大规模

Phase 3: 企业平台

硬件
A100/H100 企业级
多节点 + 负载均衡
K8s + GPU Operator

推理框架
vLLM + TensorRT-LLM

模型
多模型服务
自定义 IC 领域微调

RAG
全公司知识图谱

能力
EDA 流程深度集成
CI/CD 嵌入 LLM 审查

团队
50+ 人全公司使用

EDA CI/CD 集成

现在

0 - 6 个月

6 月

6 - 18 个月

12 月

18 月

18 - 36 个月

24 月

36 月